

# Lojistik Regresyon – Performans Metrikleri

Atil Samancioglu

## 1 Giriş

Lojistik regresyon, sınıflandırma problemlerinde kullanılan güçlü bir algoritmadır. Bu algoritmanın başarımını ölçmek için doğrusal regresyondan farklı metriklere ihtiyaç duyulur. Bu dökümanda özellikle **binary classification** problemleri için kullanılan *Confusion Matrix*, *Accuracy*, *Precision*, *Recall* ve *F1/F<sub>β</sub>core* gibi metrikler açıklanacaktır.

## 2 Confusion Matrix (Karmaşıklık Matrisi)

Confusion matrix, sınıflandırma problemlerinde modelin doğru ve yanlış tahminlerini dört kategoriye ayırır:

- **True Positive (TP)**: Gerçek değer pozitif, tahmin de pozitif.
- **True Negative (TN)**: Gerçek değer negatif, tahmin de negatif.
- **False Positive (FP)**: Gerçek değer negatif, tahmin pozitif.
- **False Negative (FN)**: Gerçek değer pozitif, tahmin negatif.

### Confusion Matrix

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

Figure 1: Confusion Matrix bileşenleri.

## Accuracy (Doğruluk)

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Genel olarak modelin ne kadar doğru tahmin yaptığını gösterir. Ancak **dengesiz veri kümelerinde** yanıltıcı olabilir.

## 3 Precision ve Recall

### Precision (Kesinlik)

$$\text{Precision} = \frac{TP}{TP + FP}$$

Modelin pozitif tahminleri arasında, kaç tanesinin gerçekten pozitif olduğunu ölçer.

### Recall (Duyarlılık)

$$\text{Recall} = \frac{TP}{TP + FN}$$

Gerçek pozitif örneklerden kaç tanesini modelin doğru tahmin ettiğini gösterir.

## Kullanım Senaryoları

**Precision'ın önemli olduğu durumlar:**

- Spam sınıflandırma: Gerçek spam olmayan e-postaların yanlışlıkla spam olarak işaretlenmemesi gerekir. FP azaltılmalı → Precision yüksek olmalı.

**Recall'ın önemli olduğu durumlar:**

- Hastalık teşhisi (örneğin diyabet): Hasta bir bireyin hasta değil olarak sınıflandırılması ciddi bir hatadır. FN azaltılmalı → Recall yüksek olmalı.

## 4 $F_1$ ve $F_\beta$ skorları

Precision ve Recall metrikleri arasında denge sağlamak için kullanılır.

### F1 Skoru

$$F_1 = \frac{2 \cdot (\text{Precision} \cdot \text{Recall})}{\text{Precision} + \text{Recall}}$$

## **F<sub>β</sub> skoru**

$$F_{\beta} = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precision}) + \text{Recall}}$$

- $\beta = 1$ : Precision ve Recall eşit ağırlıkta (F1).
- $\beta < 1$ : Precision daha önemli (örnek: F<sub>0.5</sub>).
- $\beta > 1$ : Recall daha önemli (örnek: F<sub>2</sub>).

F-skoru daima 0 ile 1 arasında bir değer alır. Bu değer 1'e yaklaştıkça modelin hem **precision** hem de **recall** açısından güçlü olduğu anlaşılır.  $F$ -skorunun 0'a yaklaşması ise modelin bu iki metriktan en az birinde ciddi sorunlar yaşadığını gösterir.

## **5 Sonuç**

Logistic regresyon modellerinin başarımını anlamak için sadece doğruluk (accuracy) yeterli olmayabilir. Özellikle dengesiz veri kümelerinde precision, recall ve F1/F<sub>β</sub> skorları oldukça önemlidir. Hangi metriğin kullanılacağı, probleme ve risklere göre değişir.